SAP - projekt - Milijarderi

Uspjeh učenika u nastavi

Dora Bezuk, Marcela Matas, Josip Arelic, Domagoj Marinello

13.11.2022.

Uvod

Pitanja:

- 1. Ima li neki kontinent statistički značajno više miljarda?
- 2. Jesu li milijarderi koji su nasljedili bogastvo statistički značajno bogatiji od onih koji nisu?
- 3. Možete li iz danih varijabli predvidjeti njihovo bogatstvo?
- 4. Kada biste birali karijeru isključivo prema kriteriju da se obogatite, koju biste industriju izabrali? Dodatna pitanja:
 - 5. ???

Deskriptivna analiza

```
# Pomoćna funkcija za izbacivanje stršećih vrijednosti
remove_outliers <- function(data, data_column) {</pre>
  quartiles <- quantile(data_column, probs=c(.25, .75), na.rm = FALSE)
  IQR <- IQR(data_column)</pre>
  Lower <- quartiles[1] - 1.5*IQR
  Upper <- quartiles[2] + 1.5*IQR</pre>
 return(subset(data, data_column >= Lower & data_column <= Upper))</pre>
cat('\n Dimenzija podataka: ', dim(bill_data))
##
## Dimenzija podataka: 2614 22
for (col_name in names(bill_data)){
  if (sum(is.na(bill data[,col name])) > 0){
    cat('Ukupno nedostajućih vrijednosti za varijablu'
        ,col_name, ': ', sum(is.na(bill_data[,col_name])),'\n')
  }
}
## Ukupno nedostajućih vrijednosti za varijablu company.name : 38
## Ukupno nedostajućih vrijednosti za varijablu company.relationship:
## Ukupno nedostajućih vrijednosti za varijablu company.sector : 23
```

```
## Ukupno nedostajućih vrijednosti za varijablu company.type : 36
## Ukupno nedostajućih vrijednosti za varijablu demographics.gender : 34
## Ukupno nedostajućih vrijednosti za varijablu wealth.type : 22
## Ukupno nedostajućih vrijednosti za varijablu wealth.how.category : 1
## Ukupno nedostajućih vrijednosti za varijablu wealth.how.industry : 1
```

Postoje podaci koji nedostaju. Što s njima?

Pitanja

- 1. Ima li neki kontinent statistički značajno više miljarda?
- 2. Jesu li milijarderi koji su nasljedili bogastvo statistički značajno bogatiji od onih koji nisu?

```
# Učitavanje podataka iz excel datoteke
inherited = bill_data[bill_data$wealth.how.inherited!="not inherited",]
print(inherited)
## # A tibble: 926 x 22
##
                     rank year company.founded company.name
                                                                 company.relation~
##
      <chr>
                    <dbl> <dbl>
                                      <dbl> <chr>
                                                                 <chr>
##
  1 Oeri Hoffman ~
                        3 1996
                                          1896 F. Hoffmann-La ~ <NA>
                        6 1996
   2 Walter Thomas~
                                           1963 Sun Hung Kai Pr~ Relation
## 3 Charles Koch
                        6 2014
                                          1940 Koch industries relation
## 4 David Koch
                       6 2014
                                           1940 Koch industries relation
## 5 Jim Walton
                       7 2001
                                           1962 Walmart
                                                                 relation
                       8 1996
## 6 Yoshiaki Tsut~
                                           1894 Seibu Corporati~ relation
## 7 John Walton
                        8 2001
                                           1962 Walmart
                                                                relation
## 8 Theo and Karl~
                        9 1996
                                           1913 Aldi Nord
                                                                 Relation
                        9 2001
## 9 S Robson Walt~
                                           1962 Walmart
                                                                relation
                        9 2014
## 10 Christy Walton
                                           1962 Walmart
                                                                 relation
## # ... with 916 more rows, and 16 more variables: company.sector <chr>,
      company.type <chr>, demographics.age <dbl>, demographics.gender <chr>,
      location.citizenship <chr>, location.country code <chr>,
## #
      location.gdp <dbl>, location.region <chr>, wealth.type <chr>,
## #
      wealth.worth in billions <dbl>, wealth.how.category <chr>,
      wealth.how.from emerging <chr>, wealth.how.industry <chr>,
      wealth.how.inherited <chr>, wealth.how.was founder <chr>, ...
non_inherited = bill_data[bill_data$wealth.how.inherited=="not inherited",]
print(non_inherited)
## # A tibble: 1,688 x 22
##
     name
                       rank year company.founded company.name
                                                                  company.relatio~
##
      <chr>
                      <dbl> <dbl>
                                            <dbl> <chr>
                                                                  <chr>
##
  1 Bill Gates
                          1 1996
                                             1975 Microsoft
                                                                  founder
## 2 Bill Gates
                          1 2001
                                             1975 Microsoft
                                                                  founder
## 3 Bill Gates
                          1 2014
                                             1975 Microsoft
                                                                  founder
## 4 Warren Buffett
                          2 1996
                                             1962 Berkshire Hath~ founder
## 5 Warren Buffett
                          2 2001
                                             1962 Berkshire Hath~ founder
## 6 Carlos Slim Helu
                          2 2014
                                             1990 Telmex
                                                                  founder
                          3 2001
## 7 Paul Allen
                                             1975 Microsoft
                                                                  founder
```

1975 Zara

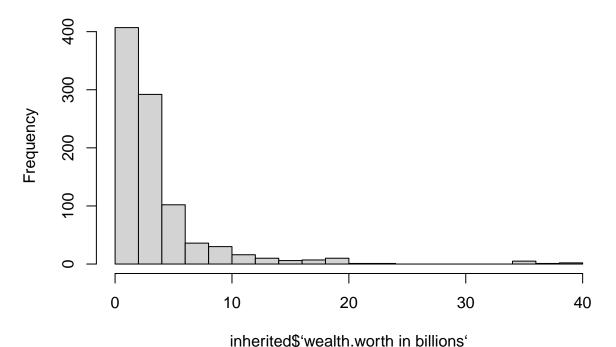
founder

3 2014

8 Amancio Ortega

```
## 9 Lee Shau Kee
                             1996
                                              1976 Henderson Land~ founder/chairman
## 10 Larry Ellison
                           4 2001
                                              1977 Oracle
                                                                   founder
## # ... with 1,678 more rows, and 16 more variables: company.sector <chr>,
       company.type <chr>, demographics.age <dbl>, demographics.gender <chr>,
      location.citizenship <chr>, location.country code <chr>,
## #
      location.gdp <dbl>, location.region <chr>, wealth.type <chr>,
      wealth.worth in billions <dbl>, wealth.how.category <chr>,
       wealth.how.from emerging <chr>, wealth.how.industry <chr>,
## #
       wealth.how.inherited <chr>, wealth.how.was founder <chr>, ...
inherited_mean = mean(inherited$`wealth.worth in billions`)
print(inherited_mean)
## [1] 3.750756
hist(inherited$`wealth.worth in billions`, breaks = 20)
```

Histogram of inherited\$'wealth.worth in billions'



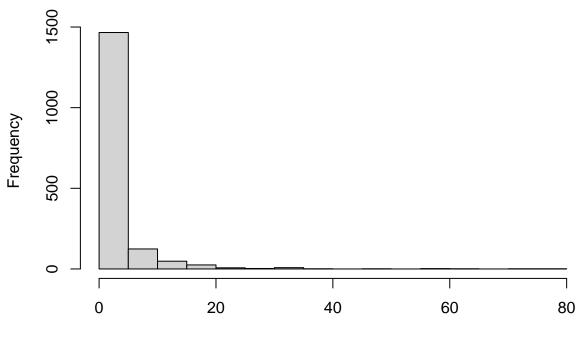
/ Walter the state of the state

non_inherited_mean = mean(non_inherited\$`wealth.worth in billions`)
print(non_inherited_mean)

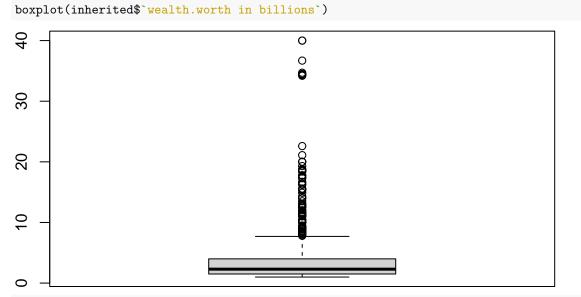
[1] 3.411908

hist(non_inherited\$`wealth.worth in billions`, breaks = 20)

Histogram of non_inherited\$'wealth.worth in billions'



non_inherited\$'wealth.worth in billions'



boxplot(non_inherited\$`wealth.worth in billions`)

wilcox.test(inherited_mean, non_inherited_mean, alternative = "two.sided")

```
##
## Wilcoxon rank sum exact test
##
## data: inherited_mean and non_inherited_mean
## W = 1, p-value = 1
## alternative hypothesis: true location shift is not equal to 0
# jel smijem odrezat dio podataka (pogledati histogram i box plot), koji dio?
# ako ne, koji test koristi? t-test za mediane umjesto meana? ili neparametarski test? kao sto je wilco
```

Formiranje hipoteza

Vizualizacija podataka

Pretpostavke za provođenje testa

Test xy

Provođenje T-testa

Zaključak

- 3. Možete li iz danih varijabli predvidjeti njihovo bogatstvo?
- 4. Kada biste birali karijeru isključivo prema kriteriju da se obogatite, koju biste industriju izabrali?

Pretpostavljamo da karijerom u određenoj industriji, a ne nasljedstvom zarađujemo novac. Zbog toga gledamo samo milijardere koji nisu nasljedili svoje bogatstvo.

