SAP - projekt - Milijarderi

Uspjeh učenika u nastavi

Dora Bezuk, Marcela Matas, Josip Arelic, Domagoj Marinello

13.11.2022.

Uvod

Pitanja:

- 1. Ima li neki kontinent statistički značajno više miljarda?
- 2. Jesu li milijarderi koji su nasljedili bogastvo statistički značajno bogatiji od onih koji nisu?
- 3. Možete li iz danih varijabli predvidjeti njihovo bogatstvo?
- 4. Kada biste birali karijeru isključivo prema kriteriju da se obogatite, koju biste industriju izabrali? Dodatna pitanja:
 - 5. ???

Deskriptivna analiza

```
# Pomoćna funkcija za izbacivanje stršećih vrijednosti
remove_outliers <- function(data, data_column) {</pre>
  quartiles <- quantile(data_column, probs=c(.25, .75), na.rm = FALSE)
  IQR <- IQR(data_column)</pre>
  Lower <- quartiles[1] - 1.5*IQR
  Upper <- quartiles[2] + 1.5*IQR</pre>
 return(subset(data, data_column >= Lower & data_column <= Upper))</pre>
cat('\n Dimenzija podataka: ', dim(bill_data))
##
## Dimenzija podataka: 2614 22
for (col_name in names(bill_data)){
  if (sum(is.na(bill data[,col name])) > 0){
    cat('Ukupno nedostajućih vrijednosti za varijablu'
        ,col_name, ': ', sum(is.na(bill_data[,col_name])),'\n')
  }
}
## Ukupno nedostajućih vrijednosti za varijablu company.name : 38
## Ukupno nedostajućih vrijednosti za varijablu company.relationship:
## Ukupno nedostajućih vrijednosti za varijablu company.sector : 23
```

```
## Ukupno nedostajućih vrijednosti za varijablu company.type : 36
## Ukupno nedostajućih vrijednosti za varijablu demographics.gender : 34
## Ukupno nedostajućih vrijednosti za varijablu wealth.type : 22
## Ukupno nedostajućih vrijednosti za varijablu wealth.how.category : 1
## Ukupno nedostajućih vrijednosti za varijablu wealth.how.industry : 1
Postoje podaci koji nedostaju. Što s njima?
```


Pitanja

- 1. Ima li neki kontinent statistički značajno više miljarda?
- 2. Jesu li milijarderi koji su nasljedili bogastvo statistički značajno bogatiji od onih koji nisu?

```
# Učitavanje podataka iz excel datoteke
inherited = bill_data[bill_data$wealth.how.inherited!="not inherited",]
print(inherited)
## # A tibble: 926 x 22
##
      name
                rank year compa~1 compa~2 compa~3 compa~4 compa~5 demog~6 demog~7
##
      <chr>
                <dbl> <dbl>
                              <dbl> <chr>
                                            <chr>
                                                    <chr>
                                                            <chr>
                                                                      <dbl> <chr>
##
   1 Oeri Hof~
                   3 1996
                               1896 F. Hof~ <NA>
                                                                          O <NA>
                                                    pharma~ new
##
   2 Walter T~
                    6 1996
                               1963 Sun Hu~ Relati~ real e~ new
                                                                          0 male
                    6 2014
## 3 Charles ~
                               1940 Koch i~ relati~ Oil re~ new
                                                                         78 male
## 4 David Ko~
                    6 2014
                               1940 Koch i~ relati~ Oil re~ new
                                                                         73 male
                               1962 Walmart relati~ retail new
## 5 Jim Walt~
                   7 2001
                                                                         53 male
## 6 Yoshiaki~
                   8 1996
                               1894 Seibu ~ relati~ real e~ aquired
                                                                         61 male
##
  7 John Wal~
                   8 2001
                              1962 Walmart relati~ retail new
                                                                         55 male
## 8 Theo and~
                    9 1996
                                                                          0 male
                              1913 Aldi N~ Relati~ grocer~ new
## 9 S Robson~
                    9 2001
                               1962 Walmart relati~ retail new
                                                                         57 male
                    9 2014
## 10 Christy ~
                               1962 Walmart relati~ retail new
                                                                         59 female
## # ... with 916 more rows, 12 more variables: location.citizenship <chr>,
       `location.country code` <chr>, location.gdp <dbl>, location.region <chr>,
       wealth.type <chr>, `wealth.worth in billions` <dbl>,
## #
       wealth.how.category <chr>, `wealth.how.from emerging` <chr>,
       wealth.how.industry <chr>, wealth.how.inherited <chr>,
       `wealth.how.was founder` <chr>, `wealth.how.was political` <chr>, and
       abbreviated variable names 1: company.founded, 2: company.name, ...
non_inherited = bill_data[bill_data$wealth.how.inherited=="not inherited",]
print(non_inherited)
## # A tibble: 1,688 x 22
##
                 rank year compa~1 compa~2 compa~3 compa~4 compa~5 demog~6 demog~7
##
      <chr>
                <dbl> <dbl>
                              <dbl> <chr>
                                            <chr>
                                                    <chr>
                                                            <chr>
                                                                      <dbl> <chr>
##
   1 Bill Gat~
                    1 1996
                               1975 Micros~ founder Softwa~ new
                                                                         40 male
  2 Bill Gat~
                    1 2001
                               1975 Micros~ founder Softwa~ new
                                                                         45 male
## 3 Bill Gat~
                      2014
                               1975 Micros~ founder Softwa~ new
                    1
                                                                         58 male
## 4 Warren B~
                   2 1996
                               1962 Berksh~ founder Finance new
                                                                         65 male
## 5 Warren B~
                   2 2001
                               1962 Berksh~ founder Finance new
                                                                         70 male
                              1990 Telmex founder Commun~ privat~
## 6 Carlos S~
                   2 2014
                                                                         74 male
                   3 2001
## 7 Paul All~
                               1975 Micros~ founder techno~ new
                                                                         48 male
## 8 Amancio ~
                              1975 Zara
                   3 2014
                                           founder Fashion new
                                                                         77 male
```

```
## 9 Lee Shau~
                      1996
                               1976 Hender~ founde~ real e~ new
                                                                         68 male
                      2001
## 10 Larry El~
                    4
                               1977 Oracle founder softwa~ new
                                                                         56 male
## # ... with 1,678 more rows, 12 more variables: location.citizenship <chr>,
       `location.country code` <chr>, location.gdp <dbl>, location.region <chr>,
      wealth.type <chr>, `wealth.worth in billions` <dbl>,
## #
      wealth.how.category <chr>, `wealth.how.from emerging` <chr>,
      wealth.how.industry <chr>, wealth.how.inherited <chr>,
       `wealth.how.was founder` <chr>, `wealth.how.was political` <chr>, and
## #
       abbreviated variable names 1: company.founded, 2: company.name, ...
inherited_mean = mean(inherited$`wealth.worth in billions`)
print(inherited_mean)
## [1] 3.750756
hist(inherited$`wealth.worth in billions`, breaks = 20)
```


Histogram of inherited\$`wealth.worth in billions`



```
non_inherited_mean = mean(non_inherited$`wealth.worth in billions`)
print(non_inherited_mean)


## [1] 3.411908
hist(non_inherited$`wealth.worth in billions`, breaks = 20)
```

Histogram of non_inherited\$`wealth.worth in billions`




non_iiinchedo wealth.worth in billions

boxplot(inherited\$`wealth.worth in billions`)



boxplot(non_inherited\$`wealth.worth in billions`)



```
wilcox.test(inherited_mean, non_inherited_mean, alternative = "two.sided")

##

## Wilcoxon rank sum exact test

##

## data: inherited_mean and non_inherited_mean

## W = 1, p-value = 1

## alternative hypothesis: true location shift is not equal to 0

# jel smijem odrezat dio podataka (pogledati histogram i box plot), koji dio?

# ako ne, koji test koristi? t-test za mediane umjesto meana? ili neparametarski test? kao sto je wilco
```

Formiranje hipoteza

Vizualizacija podataka

Pretpostavke za provođenje testa

Test xy

Provođenje T-testa

Zaključak

- 3. Možete li iz danih varijabli predvidjeti njihovo bogatstvo?
- 4. Kada biste birali karijeru isključivo prema kriteriju da se obogatite, koju biste industriju izabrali?

Pretpostavljamo da karijerom u određenoj industriji, a ne nasljedstvom zarađujemo novac. Zbog toga gledamo samo milijardere koji nisu nasljedili svoje bogatstvo. Također, zanimaju nas samo najnoviji milijarderi odnosno oni s popisa iz 2014. godine.

